

知识图谱与大语言模型协同的个性化学习推荐

张学飞, 张丽萍*, 闫 盛, 侯 敏, 赵宇博

(内蒙古师范大学 计算机科学技术学院, 呼和浩特 010022)

(* 通信作者电子邮箱 cieczip@imnu.edu.cn)

摘要: 个性化学习推荐是智慧教育领域的重要研究课题, 它的核心目标是利用推荐算法和模型为学习者提供与他们的个人学习需求、兴趣、能力和历史相匹配的有效学习资源, 从而提高学习者的学习效果。目前的推荐方法存在冷启动、数据稀疏、可解释性差和过度个性化等问题, 而知识图谱与大语言模型的结合为解决上述问题提供了有力支持。首先, 对个性化学习推荐的概念、研究现状等内容进行概述; 其次, 分别讨论知识图谱和大语言模型(LLM)的概念以及在个性化学习推荐中的具体应用; 再次, 总结知识图谱与LLM在个性化学习推荐中协同应用的方法; 最后, 展望知识图谱和LLM在个性化学习推荐中的未来发展方向, 从而为个性化学习推荐领域的持续发展和创新实践提供借鉴和启示。

关键词: 知识图谱; 大语言模型; 个性化学习推荐; 推荐算法; 学习资源

中图分类号: TP18 **文献标志码:** A

Personalized learning recommendation in collaboration of knowledge graph and large language model

ZHANG Xuefei, ZHANG Liping*, YAN Sheng, HOU Min, ZHAO Yubo

(College of Computer Science and Technology, Inner Mongolia Normal University, Hohhot Inner Mongolia 010022, China)

Abstract: As an important research topic in the field of smart education, personalized learning recommendation has a core goal of using recommendation algorithms and models to provide learners with effective learning resources that match their individual learning needs, interests, abilities, and histories, so as to improve learners' learning effects. Current recommendation methods have problems such as cold start, data sparsity, poor interpretability, and over-personalization, and the combination of knowledge graph and Large Language Model (LLM) provides strong support to solve the above problems. Firstly, the contents such as concepts and current research status of personalized learning recommendation were overviewed. Secondly, the concepts of knowledge graph and LLM and their specific applications in personalized learning recommendation were discussed respectively. Thirdly, the collaborative application methods of knowledge graph and LLM in personalized learning recommendation were summarized. Finally, the future development directions of knowledge graph and LLM in personalized learning recommendation were prospected to provide reference and inspiration for continuous development and innovative practice in the field of personalized learning recommendation.

Key words: knowledge graph; Large Language Model (LLM); personalized learning recommendation; recommendation algorithm; learning resource

0 引言

个性化学习^[1]是一种教育理念和方式, 它的核心目标在于充分挖掘和发挥每位学生的学习潜能, 以实现学习能力的最大化。这种策略强调根据每个学生的独特需求、兴趣和风格设计, 从而为学生提供量身定制的学习体验^[2]。通过个性化学习, 教育者能够更精准地满足学生的个别差异, 促进每位学生在知识掌握、技能发展和创造力培养等方面的全面发展。

个性化学习推荐是实现个性化学习理念的关键技术手段。首先, 它通过分析学习者数据建立学习推荐模型; 其次, 应用学习推荐算法并结合教育目标从可用的学习资源中选择最相关的学习内容; 最后, 整合学习者反馈, 实时优化推荐算法以提供更有针对性的学习资源。

传统个性化学习推荐方法通过分析学习者的行为和偏好提供定制化资源, 虽然能够提升学习效率和体验, 但面临冷启动^[3]、数据稀疏、可解释性差、过度个性化等挑战。人工

收稿日期: 2024-07-10; 修回日期: 2024-09-25; 录用日期: 2024-10-09。

基金项目: 国家自然科学基金资助项目(61462071); 内蒙古自然科学基金资助项目(2023LHMS06009, 2024MS06020); 内蒙古自治区教育科学研究“十四五”规划2023年度课题(2023NGHZXZH119, NGJGH2023234)。

作者简介: 张学飞(1997—), 男, 内蒙古乌兰察布人, 硕士研究生, CCF会员, 主要研究方向: 计算机教育; 张丽萍(1974—), 女, 内蒙古呼和浩特人, 教授, 硕士, 主要研究方向: 智慧教育、软件工程; 闫盛(1984—), 男, 内蒙古包头人, 讲师, 硕士, CCF会员, 主要研究方向: 计算机教育; 侯敏(1973—), 女, 内蒙古乌兰察布人, 副教授, 硕士, 主要研究方向: 计算机教育; 赵宇博(1999—), 男, 内蒙古赤峰人, 硕士研究生, CCF会员, 主要研究方向: 知识图谱、教育数据挖掘。

智能技术的融合应用对个性化学习推荐进行重塑和再造^[4],帮助克服了传统个性化学习推荐方法的局限性,提高推荐的相关性和准确性。

知识图谱(Knowledge Graphs, KG)和大语言模型(Large Language Model, LLM)是人工智能领域的关键技术,为个性化学习推荐提供强大技术支持。知识图谱是一种结构化的语义知识库,它将现实世界中的实体和它们之间的关系用图的形式表示。例如,维基百科和Huapu,是结构化的知识模型,可以储存和丰富事实知识,是促进个性化学习推荐发展的重要手段。然而,知识图谱构建和持续更新很复杂,这给现有方法在生成新事实知识和捕捉未明确表述知识方面的能力带来了挑战。大语言模型是一类具有大量参数的自然语言处理(Natural Language Processing, NLP)模型。如GPT-4(Generative Pre-trained Transformer-4),由于突出的语言处理能力、通用知识以及泛化能力,在教育领域中越来越受到关注,尤其是在个性化学习推荐方面。但是,大语言模型是黑盒模型,它们的内部工作机制对于外部观察者来说不透明,这使理解和验证模型的决策过程变得困难,通常无法捕捉和获取事实知识。具体来说,大语言模型可能会记忆训练语料库中包含的事实和知识,但研究表明,它们总是无法回忆出这些事实,而且有时还会出现幻觉问题^[5],即生成具有错误事实的表述。与此相反,知识图谱可以为推理和可解释性提供外部知识增强大语言模型^[6]。知识图谱作为融合全面的学科知识点与教学资源的知识库,不仅能够教育数据分析、学科资料的整理归纳、学习推荐建模以及学习资源的个性化推荐等方面发挥重要的基础性作用,还能够促进学习者由简单的知识学习向思维发展进行转变。因此,大语言模型和知识图谱的结合可以相互增强,提高个性化学习推荐的效果。大语言模型的NLP能力可以提升知识图谱的嵌入、补全和构建过程,而知识图谱的结构化知识可以增强大语言模型的预训练、推理和可解释性,同时发挥它们的优势在个性化学习推荐应用中至关重要。

本文从个性化学习推荐出发,探讨了知识图谱和大语言模型在个性化学习推荐中的应用,并分析两者的协同作用及其在教育领域的潜力,研究框架如图1所示。




图1 研究框架

Fig. 1 Research framework

本文的主要工作如下:

1)个性化学习推荐概述。个性化学习推荐的核心在于理解每个学习者的独特需求,并推荐相应的学习资源。针对传统推荐方法存在的问题,提出知识图谱和大语言模型的个性化学习推荐,旨在为学习者提供更贴合能力和兴趣的学习内容,从而提高学习效率和成果。

2)基于知识图谱的个性化学习推荐。知识图谱以它的表示和管理海量知识的独特优势,为推荐任务提供高质量的结构化知识。本文介绍了知识图谱应用推荐任务的一些方

法,目的是提升推荐个性化和准确性以及优化教育资源的整合与应用,从而推动教育智能化的发展。

3)基于大语言模型的个性化学习推荐。大语言模型通过在海量的文本数据上预训练具备了强大的语义理解能力,能够捕捉和理解学习者的查询意图和偏好,准确推荐相关学习资源。本文介绍了大语言模型应用推荐任务的一些方法,有助于实现更智能和个性化的推荐服务。

4)知识图谱与大语言模型协同的个性化学习推荐。知识图谱与大语言模型协同应用旨在为学习者提供一个全面的知识学习和理解平台,提高学习的相关性和个性化程度,增强学习过程的互动性和趣味性,在个性化学习推荐中更精准和高效。本文分别总结了在个性化学习推荐中知识图谱增强大语言模型预训练、推理结果、可解释性以及大语言模型增强知识图谱嵌入、补全、构建的方法,为个性化学习推荐提供更广阔应用前景。

最后总结知识图谱和大语言模型应用在个性化学习推荐中的问题与挑战,期望通过结合知识图谱与人工智能技术促进与教育体系深度融合,从而推动个性化学习推荐领域的持续和创新发展。

1 个性化学习推荐

个性化学习推荐是一种教育技术,它利用算法和数据分析为学习者提供定制化的学习资源、推荐路径和教学策略。这种技术考虑了学习者的个人目标、兴趣、能力、学习风格和学习反馈,目的是最大化学习者的学习能力和效果,同时激发他们的学习潜力。在教育环境中实施这种技术,可以为学习者提供更贴合个人需求的学习体验,从而促进他们的全面发展。

传统的推荐方法为个性化学习推荐的发展奠定了基础,但同时存在一些局限性。吴正洋等^[7]将传统的推荐方法归纳为基于内容的学习推荐、协同过滤学习推荐、混合学习推荐。基于内容的学习推荐^[8]通过分析、挖掘、利用学习材料内容特征进行推荐,有利于精确匹配学习材料与学习者的具体需求和知识水平,但可能会忽略学习者的行为模式和偏好演变。协同过滤学习推荐^[9]是一种基于学习者和学习资源之间的历史交互行为生成推荐的算法,这种方法可以推荐出与学习者已知喜好相似但不同的学习资源,增加推荐的多样性,但存在数据稀疏、冷启动等问题。混合学习推荐^[10]结合多个推荐算法能够提高推荐的准确性和覆盖度,但带来了推荐复杂度提升、推荐算法权重分配不均等问题。

个性化学习推荐的核心在于通过理解学习者的个性特征,包括他们的知识水平、学习风格、兴趣偏好以及教学目标,从而推荐符合需求的学习内容和教学策略^[11]。传统推荐方法在个性化学习推荐领域发挥了重要作用,但它们仍需解决一些关键问题,如动态适应学习者偏好变化、处理数据稀疏和冷启动问题以及优化多算法集成的复杂性和效率。随着人工智能技术的发展,特别是知识图谱和大语言模型的应用,为克服这些局限性提供了新的可能性和方向。因此,从知识图谱与大语言模型出发,对个性化学习推荐方法进行更详细讨论。

2 基于知识图谱的个性化学习推荐

在维基百科的官方词条中:知识图谱(KG)是Google用

于增强其搜索引擎功能的知识库^[12]。本质上,KG是一种图形化结构,将结构化数据存储为三元组 $KG = \{(h, r, t) \subseteq \mathcal{E} \times \mathcal{R} \times \mathcal{E}\}$, 其中: h 是头实体; r 是尾实体; t 是实体之间的关系; $\mathcal{E}$ 和 $\mathcal{R}$ 分别代表实体和关系。现有的知识图谱可根据存储的信息分为4类^[13],如图2所示,分别是百科全书式知识图谱、常识性知识图谱、领域特定知识图谱和多模态知识图谱。1)百科全书式知识图谱(Encyclopedia KG)^[14]:将百科全书中的知识整理出来,形成一个具有结构化信息的知识图谱,为学习者提供翔实全面的知识体系。2)常识性知识图谱(Common Sense KG)^[15]:致力于模拟和表达人类日常生活中的常识性知识,包含大量的概念、实体、属性以及它们之间的关系,对于提升机器的理解和推理能力至关重要。3)领域特定知识图谱(Domain-Specific KG)^[16]:针对某一特定领域或主题构建的知识图谱,包含该领域内的概念、实体、关系以及它们之间的交互和联系。这种类型的知识图谱对于特定领域的数据分析、决策支持和智能应用具有重要价值。4)多模态知识图谱(Multimodal KG)^[17]:一种结合了文本、图像、声音等多种数据模态的知识图谱,它不仅包含传统知识图谱中的结构化文本信息,还融合了视觉、听觉等其他模态的数据,以更全面地表达和理解现实世界中的复杂概念和关系。




图2 知识图谱分类

Fig. 2 Knowledge graph classification

教育知识图谱(Educational KG, Edu-KG)作为领域特定知识图谱的一种,以其表示和管理海量知识的独特优势,为推荐任务提供高质量的结构化知识^[18]。基于Edu-KG的个性化学习推荐是一种基于KG的智能化教育方法,该方法通过收集和分析学习者的历史学习数据与偏好,构建个性化的学生模型,利用Edu-KG精确匹配学生的学习需求,生成定制化的学习推荐列表,并根据学生的实时反馈动态调整推荐内容,实现高度个性化的学习推荐^[19]。

KG在个性化学习推荐领域的应用能够显著提升学习资源推荐的质量,实现更精准和高效的教育服务。因此,研究者们通过整合KG和先进的学习分析技术,提出了多种创新方法以提升学习者的积极性和学习效果。

通过结合KG表示学习结构,可以生成符合学习者个性化需求的学习资源推荐。Zhang等^[20]提出了一种基于Edu-KG的个性化学习资源推荐模型(Personalized Learning Resource Recommendation model based on Edu-KG, Edu-KG-PLRR),该模型通过学习者偏好集的构建和实体嵌入过程中的权重融合,扩展学习资源特征,并利用偏好传播机制挖掘潜在联系,更充分地表达学生的个性化知识需求。针对课程

资源推荐,Li等^[21]研究了一种基于大规模在线开放课程(Massive Open Online Course, MOOC)系统的个性化推荐方法,结合深度学习与大数据技术,在海量数据中快速找到用户感兴趣的课程,为知识的精准传播作出非常重要的贡献。

利用KG结构化信息为学习者提供精准且个性化学习路径推荐。Zhang等^[22]提出了一种基于知识图谱的细粒度、多情境感知的在线学习社区学习路径推荐模型,通过捕捉用户的动态学习特征和潜在知识水平,促进学习者加深知识理解。为了能够充分利用知识图谱的结构化信息,Zhang等^[23]提出一种集成知识图谱和图卷积网络(Graph Convolutional Network, GCN)的个性化学习路径推荐方法,这种方法通过结合KG以及充分利用GCN的强大特征学习能力,提供更精准和个性化的学习路径推荐;同时,通过考虑学习资源的多维特征和学习者的个性化需求,该算法能够生成更具针对性的学习计划,有助于提升学习效率和学习者满意度。

KG不仅作为数据整合和分析的工具,而且作为推荐和解释个性化学习策略的基础,帮助学习者更有效地达成目标。因此,Shou等^[24]提出一种基于交互行为偏好的个性化知识图谱推荐算法,根据学习者对知识点的交互程度、掌握程度以及学习效果进行协同分析,实现了在线学习环境下的个性化学习。通过整合学科知识图谱、学习者画像、个性化推荐和反馈,Duan等^[25]提出一种个性化推荐框架。该框架关注学习者的个体特征和学习反馈,利用动态增长的教育资源支持学习者的个性化学习。通过结合知识图谱和级别嵌入模块,Jung等^[26]提出KPCR(Knowledge graph enhanced Personalized Course Recommendation)框架,不仅提高了推荐系统的准确性,而且通过学习者的反馈进一步验证了推荐系统的实用性和学习者的接受度。

文本在知识图谱推荐系统中具有丰富语义信息、上下文感知、解释性等优势,但面临模态间融合不足、有噪声和歧义、数据稀疏、实时处理能力差等问题挑战。因此,如何更好地融合多模态数据,提高推荐系统的整体性能需要进一步研究。目前的知识图谱推荐系统在整合多模态数据方面存在局限,主要因为现有方法依赖于分别提取视觉和文本表示的独立模型,这导致2种模态之间的有效融合不够完善。此外,尽管学者们尝试利用多模态信息计算节点间的相似度,但这些尝试在提升推荐系统性能方面尚未取得突破性进展。针对上述问题,研究者们在多模态知识图谱的个性化推荐方面进行探索。Wei等^[27]提出一种动量对比多模态知识图谱学习推荐框架(Momentum contrastive Multi-Modal Knowledge Graph learning framework for Recommendation, M3KGR),该框架结合CLIP(Contrastive Language-Image Pre-training)模型^[28]提取的文本和视觉表示,有效整合了多模态数据,并采用多模态增强注意力技术和动量对比方法提高图注意力网络的性能并解决数据稀疏与噪声问题,显著提升了推荐系统的效果。Sun等^[29]首次提出将多模态知识图谱融入推荐系统,开发了一种创新的多模态知识图谱注意力网络(Multi-modal Knowledge Graph Attention network, MKGAT)。MKGAT的核心优势在于能够综合利用文本和图像等多模态数据类型,在提高推荐系统性能的同时,有效应对数据稀疏和冷启动问题。该网络采用先进的多模态图注意力机制,在多模态知识图谱(Multi-Modal KG, MMKG)上实现信息的有效传播,进而生成综合的嵌入表示,以提高推荐的相关性和准确性。

综上所述,研究者们通过整合KG与深度学习和GCN等先进技术,提出多种创新模型和框架提升推荐系统的性能。这些方法能够捕捉学习者的个性化需求和动态学习特征,通过分析学习者偏好、行为数据和知识掌握情况,提供精准且个性化的学习资源和路径推荐。此外,通过整合学习反馈,推荐系统能够动态调整学习策略,不断优化推荐过程,以提高学习效率和学习者满意度。这些研究工作展示了KG在教育推荐系统中的重要作用,可以实现教育资源的高效组织和智能推荐,支持学习者的个性化学习需求。但是,当前基于KG的个性化学习推荐系统在实施过程中仍然面临专业知识的资源稀缺性、推荐算法更新滞后性、推荐内容的多样性和新颖性缺失等挑战。

3 基于大语言模型的个性化学习推荐

大语言模型(LLM)的横空出世,在理解人类语言、获取知识、提供个性化推荐服务等方面发挥越来越重要的作用。LLM的个性化学习推荐发展脉络如图3所示,从早期的Word2Vec、GloVe等静态词向量表示模型,到Transformer架构,再到BERT(Bidirectional Encoder Representations from Transformers)、GPT、GPT-2、GPT-3、GPT-3.5、GPT-4等^[30]预训练模型,参数规模从百亿级增加到万亿级,给模型性能带来质的飞跃,彻底颠覆了人们对人工智能的认知、应用和研究范式。它们能够参与复杂的逻辑推理、理解和生成自然语言,甚至显示出对社会现象深刻的洞察与新颖的解释^[31]。

随着人工智能的发展,以ChatGPT(Chat Generative Pre-trained Transformer)为代表的LLM在教育领域中越来越受到关注,尤其是在个性化学习推荐方面。首先,ChatGPT可以作为一个多功能的虚拟导师,通过个性化学习推荐、智能虚拟辅导以及语言翻译和学术评分,能够为学生提供定制化的知识整合、实时反馈和互动式学习体验,同时为教师提供有力的教学支持,共同促进教育的个性化和智能化发展^[32]。其次,ChatGPT可以提供智能搜索、智能问答、自动摘要与分类、智能翻译等创新场景,帮助学生获得更智能的感知、交互和知识服务等体验,为学生提供智能化、高效化、个性化的推荐服务^[33]。最后,ChatGPT通过细致整合学习反馈,当学生

未能达到预定能力水平时,它不仅会分析学生的学习行为和结果,还会给出具体的改进建议,帮助学生理解不足之处并指导学生如何提升。一旦学生达到目标并准备进入下一阶段,将对比前后阶段,明确指出学习内容的联系、差异及需要注意的关键点,确保学生对学习进度有清晰的认识^[34]。

LLM在教育领域的应用不仅提升了学习的个性化和智能化水平,还通过提供综合性的智能推荐服务,极大地丰富了学生的学习体验,同时为教师的教学决策带来了便利。但是,个性化学习推荐还存在推荐内容不能满足学习者需求、没有动态分析学习行为、学习意图没有得到很好预测等问题。为此,针对个性化学习推荐存在的问题,研究者们提出了一些结合LLM推荐的方法,以提高学习者学习效率。

传统判别式推荐系统存在可解释性差、数据稀疏、复杂特征关系捕捉不足等问题。为此,Ji等^[35]提出一种新型推荐系统方法GenRec(Generative Recommendation),该方法利用大语言模型的生成能力创建推荐以及大语言模型的理解能力解释上下文,了解用户偏好进而生成相关推荐。

针对推荐内容与学习者的需求和情绪状态不相匹配的问题,Srivastav等^[36]设计了一种命名为EdBERT的模型,通过“微调谷歌BERT”工具进行比较研究,在不同阶段进行训练,以理解语言、语境和情感,从而对学习者的反馈进行准确分类,提高学习者学习效率;但是,该模型可能存在情感和需求不一致的问题。为此,Kim等^[37]提出一种知识追踪算法,将长短期记忆单元添加到基于Transformer的模型中,该方法不仅能够删除学习者不需要解决的问题,还能推荐问题,能够确保推荐的问题不仅与学习者的知识水平相匹配,而且与他们的情感和语境需求相一致。通过整合EdBERT的情感分析和知识追踪算法的个性化问题推荐,Geng等^[38]提出一种名为P5新颖的“预训练、个性化提示和预测范式”推荐方法,它利用自然语言的强大表达能力,将不同的推荐任务统一在一个共享的文本到文本的框架下,将所有相关数据,比如用户-项目交互、描述、元数据和评论都转换为自然语言序列,以捕获深层次的语义信息,从而提供一个更全面、准确的推荐系统。




图3 LLM的个性化学习推荐发展脉络

Fig. 3 Development of LLMs for personalized learning recommendation

为了能够更准确地理解用户需求以进一步提升推荐的相关性和个性化水平,研究者们利用ChatGPT等高级推荐模型,评估它们在不同场景下的性能并结合用户交互信息反映用户潜在兴趣,从而提供更精准和贴合用户需求的推荐结果。Liu等^[39]利用ChatGPT作为一个通用推荐模型,评估ChatGPT在多个不同推荐场景下的性能,并使用少量样本提

示,注入用户交互信息来体现用户的潜在兴趣,帮助ChatGPT更准确地把握用户需求,提供更清晰合理的推荐结果。而Xu等^[40]开发的mHyER(multilingual Hypothetical Exercise Retriever)方法可以利用ChatGPT的理解能力生成假设性练习内容,并结合个性化学习推荐系统,能够有效链接学习者个性化需求与适合的练习资源,进一步提升学习体验

和效率。

综上所述,LLM在个性化学习推荐中的应用日益广泛,它们通过提供定制化的学习资源、智能辅导、语言翻译和学术评分等服务,极大地提高了学习的互动性和智能化水平。ChatGPT能通过智能搜索和问答等功能,提供高效的知识服务体验。针对个性化学习推荐的挑战,研究者们提出了多种改进模型和算法,如EdBERT、知识追踪算法、P5、GenRec等推荐方法,这些方法通过更精准地理解和预测学习者的需求,进一步提升了推荐内容的相关性和准确性。此外,在不同推荐场景中评估ChatGPT的性能,研究表明即使是在没有进行微调的情况下,利用少量样本提示,ChatGPT也能提供清晰合理的推荐结果。这些研究成果不仅展现了LLM在教育领域的应用潜力,也为未来个性化学习推荐的发展提供了新的方向,推动了教育个性化和智能化的进程。但是,目前基于LLM个性化学习的推荐方法还存在推荐结果透明度低、推理时间长、泛化能力低等问题。

4 KG与LLM协同的个性化学习推荐

KG与LLM的协同应用为个性化学习推荐带来了显著优势,如图4所示。一方面,KG提供了结构化的知识,包括实体、关系和属性,增强个性化学习推荐系统的决策能力和可解释性;另一方面,LLM则通过在大量文本数据上进行预训练,掌握了丰富的语义和结构信息,深入分析学习者学习行为、偏好和需求。这两种技术的结合不仅提高了学习推荐效率,还提高了学习体验的个性化程度。




图4 LLM与KG在个性化学习推荐中的协同应用

Fig. 4 Collaborative application of LLM and KG in personalized learning recommendation

结合KG和LLM的个性化学习推荐系统,利用KG的结构化知识增强LLM的预训练过程,为模型提供了丰富的背景知识,从而提升推理能力和决策的可解释性。同时,LLM的强大文本处理能力有助于自动化KG的构建,填补知识空白,并提高问题回答系统的精确度。这种协同作用不仅提高了推荐系统的性能,增加了推荐的准确性和个性化程度,而且促进了教育领域的应用,为学生和教师提供了更高效和丰富的学习及教学资源。

因此,将KG与LLM协同应用于个性化学习推荐中的潜力巨大,在整合学习推荐建模、推荐方法和学习反馈的过程中,KG和LLM的结合不仅优化了推荐策略,还提高了推荐系统的个性化水平,为学习者提供了更精准和高效的学习资源,推动了教育个性化和智能化的进程,为学习者创造一个更具包容性、参与度的学习环境。

4.1 知识图谱增强大语言模型

LLM在推荐任务中展现出了卓越的性能和效果。但是,LLM训练需要大量的数据,对于教育领域可能存在数据稀缺的问题。教育领域的数据通常以文字和数字的形式存储,难以直接用于语言模型训练。LLM在推理过程中可能给出看似合理但不正确或荒谬的答案,同时推理答案缺乏可解释性,导致对某些学生的推荐存在不公平性。KG作为一种结构化知识表示方法,能够精确表示知识结构。首先,KG丰富了预训练数据集,提供了更准确的语言和知识表示;其次,KG中的逻辑关系和语义信息增强了LLM的推理能力,提高了推荐结果的相关性和准确性;最后,KG中丰富的事实知识提升了推理结果的可解释性。

4.1.1 知识图谱优化大语言模型预训练

在教育领域中,尽管纯文本的语言预训练模型在处理广泛教授和学习的核心知识点方面表现出色,但是,它们在捕捉一些出现频率低以及属于“长尾”部分的知识点方面存在局限。例如,教育领域中存在着大量的知识点,其中一些是基础和核心知识点,如数学中的加法、减法或者语言学习中的常用词汇和基本语法。这些知识点被广泛教授和学习,然而,还有大量的知识点属于“长尾”部分,它们可能是特定领域的深入知识、罕见的概念或者特定文化背景下的知识。这些知识点虽然学习相对较少,但它们的总体重要性和需求不容忽视。知识图谱含有丰富的结构化知识,包含大量实体知识,可以极大地促进LLM的预训练学习效果。因此,提出很多知识图谱驱动的大语言预训练模型。通过这种方式,模型可以学习到实体之间的语义关系,从而增强其理解和生成能力,增加个性化学习推荐的语义深度。

为了在个性化学习推荐中提供强大的支持,帮助学习者更有效掌握知识,Zhang等^[41]利用大规模文本与语料库和知识图谱训练增强型语言表征模型ERNIE(Enhanced language Representation with Informative Entities),该模型可以同时充分利用词法、句法和知识信息,更好地理解语言中的实体和它们之间的关系,能够更精确地识别学习者在学习过程中提到的具体知识点和概念,从而提供个性化的学习路径和知识点推荐。根据学习者的兴趣和需求定制化学习内容,Peters等^[42]提出知识增强型BERT(Knowledge enhanced BERT, KnowBERT),将多知识库信息融合到大语言模型的预训练阶段,该模型通过提升语义理解的深度,不仅能够精确地提供学习材料和解答问题,而且能够借助知识图谱更准确地把握学习者的需求。针对大型预训练模型注入多种知识时,历史上注入的知识会被冲走的问题,Wang等^[43]提出K-Adapter模型,它可以固定保留预训练模型的原始参数并支持开发多功能知识注入模型,从而支持学习者在整个学习过程中不断积累新知识,同时保留旧知识,实现持续学习。由于预先训练的语言表征模型(Pre-trained Language Model, PLM)不能很好地捕捉文本中的事实知识。相比之下,知识嵌入(Knowledge Embedding, KE)方法可以通过信息实体有效地嵌入KG中表示关系事实,但是,传统的知识嵌入模型无法充分利用丰富的文本信息。因此,Fei等^[44]针对外部结构中丰富的事实信息,整合大规模知识图谱即BioKGLM(Language Model by incorporating Biomedical KG),来丰富语境化语言模型为信息提取的基础理解和推理提供支持。模型可以根据学习者的当前知识水平推荐相关的病例分析、最

新研究成果和相关治疗方法。

通过上述模型和技术的应用,能够解决LLM在处理低频实体和特定领域知识方面不足的问题,增强了模型的理解和生成能力,促进个性化学习推荐系统能够更好地理解学习者的需求,推荐更丰富、准确、专业的学习内容,并支持学习者的持续成长。这些技术的发展不仅推动了教育领域的创新,也为学习者带来了更高效和深入的学习体验。

4.1.2 知识图谱优化大语言模型推理

LLM在推理领域应用是近期热门研究话题,将LLM隐式的参数化知识与知识图谱中结构化的知识融合进而增强LLM的推理能力是值得探索的方案之一。本节首先介绍LLM进行推理的经典方法,其次进一步介绍KG与LLM融合共同进行推理的工作。

在推动个性化学习推荐和提升学习效率的背景下,LLM与KG的结合为解决复杂问题提供了新的视角和方法。Wei等^[45]提出一个思维链提示词构建方法,通过大语言模型完成复杂的推理任务,根据学习者的知识水平和需求,推荐合适的学习资源和解决步骤,帮助学习者逐步解决复杂问题,提升学习效率和质量。该项工作动机是人在进行复杂任务推理时通常将问题分解为多步简单问题,逐步解决每个简单问题后即可推理得到复杂问题的最终答案,在一系列数学推理^[46]、常识推理^[47]和符号推理^[48]任务中有着出色的表现。尽管LLM在各种任务中取得了巨大成功,但它们常常在幻觉问题上挣扎,尤其是在需要深度和负责任推理的场景中。Sun等^[49]提出一种新的LLM-KG集成范式“LLM $\otimes$ KG”,它将LLM视为一个代理,可以交互式地探索KG上的相关实体和关系,并根据检索到的知识执行推理并且通过引入一种名为图上思考(Think-on-Graph, ToG)的新方法进一步实现了这一范式。这种方法中,LLM代理会在KG上迭代执行束搜索,发现最有希望的推理路径,并返回最有可能的推理结果,从而具有更好的深度推理能力。ToG能够利用KG中的丰富知识帮助学习者规划最佳的学习路线,确保他们逐步掌握相关知识点。Toroghi等^[50]提出一种常识性知识图谱问题解答(common sense KG Question Answering, KGQA)方法,不仅能够提升推荐内容的质量和准确性,还能够支持学习者的深入理解和知识的持续更新。KGQA利用知识图谱中存储的关系信息回答自然语言问题,通过公理化方法提取LLM中的内在常识性知识,并将每个事实推理步骤建立在KG三元组的基础上,实现可验证的推理过程,减少了幻觉和推理错误。

综上,LLM与KG的融合为推理领域带来了新的视角和可能性。结合LLM的深度学习和KG的结构化知识,可以构建出更强大和可靠的推理系统。这种融合方法不仅提升了个性化学习推荐系统的性能,还能够支持学习者的深入理解和知识的持续更新并为学习者提供更准确的答案,提高了学习者的理解和解决问题的能力,也为教育者提供了更强大的工具,以支持和促进个性化学习推荐的发展。

4.1.3 知识图谱增强大语言模型可解释性

LLM在推理任务中取得了巨大的成功,但是,它们的黑盒属性使模型无法为预测出的事实作出解释,所以,提高LLM的可解释性至关重要。

可解释性以可理解的方式阐明模型预测背后的推理机制,建立适当的信任,无须技术专业知识。有了它,最终学习者能够了解LLM的功能、局限性和潜在缺陷。对于研究人

员和开发人员来说,解释模型行为提供洞察力,可以识别意外的偏见、风险和性能改进领域^[51]。为此,研究人员对增强LLM的可解释性进行了相关研究,研究的大致方向可分为两类:

1)知识图谱增强LLM探测:知识探测通过设计探测任务评估模型中的知识,尝试直接从模型中提取特定的知识。但是,LLM是以隐藏的方式存储知识的,因此很难找出所存储的知识;此外,LLM还存在幻觉问题,这会产生与事实相矛盾的陈述。这个问题严重影响了LLM可靠性。因此,有必要对LLM中存储的知识进行探测和验证。Zhang等^[52]提出一种利用KG加强LLM编辑的新型模型编辑方法GLAME(knowledge Graphs for LArge language Model Editing),该方法利用知识图谱增强模块揭示编辑过程中发生变化的相关知识,并在LLM内部获取它的表示。随后,设计了一个基于图的知识编辑模块,将结构化知识整合到模型编辑中,确保更新的参数不仅反映编辑知识的修改,还反映编辑过程导致的其他相关知识的变化,显著提高了编辑后LLM在使用编辑知识时的探测能力,为学习者提供更精准和可靠的知识推荐。当代的LLM容易产生幻觉,这主要源于模型内部的知识差距。为克服这一关键局限,研究人员采用了多种策略,通过纳入外部知识来增强LLM,以减少幻觉并提高推理的准确性。在这些策略中,利用知识图谱作为外部信息源已经取得了可喜的成果。Agrawal等^[53]回顾了基于知识图谱的LLM增强技术,重点关注它们在减少幻觉方面的功效。知识图谱增强检索技术通过检索增强生成模型(例如RAG(Retrieval-Augmented Generation)^[54]和RALM(Retrieval-Augmented Language Modeling)^[55])在处理知识密集型任务时提供了文档的上下文感知能力。这些技术的核心在于结合了参数化内存和非参数化内存,以扩展模型的知识,并解决LLM中的幻觉问题。具体来说,这些技术利用参数化内存,即预训练模型的强大记忆能力,以及非参数化内存,从检索到的文档中获取的记忆信息,从而提供上下文感知的文档。这样的做法有效地扩展了模型的知识范围,使它能够在生成文本时引用外部知识而不改变LLM的结构。

2)知识图谱增强LLM分析:KG提供结构化、准确的知识可以帮助LLM减少生成错误信息情况,特别是在需要准确事实信息的场景中。通过结合KG,LLM的决策过程可以更透明,学习者能够理解模型是如何得出结论的,从而提高模型的可信度,同时知识图谱中的关系和路径信息可以辅助LLM执行更复杂的推理任务,对于提高模型的理解和回答问题的能力至关重要。Chen等^[56]为问题解答任务引入了一个新的解释数据集,该数据集以一种新颖的方式整合了KG,从而为LLM决策带来了一定的透明度。数据集包括12102个问题-答案-解释三元组。数据集中的每个解释都将LLM的推理与KG中的实体和关系联系起来。解释部分包括“为什么选择”解释、“为什么不选择”解释和一系列支撑LLM决策的理由要素。利用KG和图注意力网络(Graph Attention network, GAT)找到原因要素,并将它们转化为人类可理解的“为什么选择”和“为什么不选择”的解释。通过定量和定性评估,验证了该数据集在改善LLM的上下文学习、提高个性化学习推荐准确性和透明化推荐逻辑方面的潜力。Jiang等^[57]提出HyKGE(Hypothesis Knowledge Graph Enhanced framework),一种通过整合LLM和KG来增强大语言模型的

假设知识图谱,在复杂和困难的场景中能够提供具有精确置信度的准确知识,同时增加一个片段重新排序模块,通过分而治之的思想,重新排列和整合检索到的知识,进一步提升学习者查询和外部知识推理路径之间的对齐效果。HyKGE可以根据学习者的查询和知识背景,提供最相关和准确的知识,并根据学习者反馈不断调整推荐内容,不仅提高了个性化学习推荐的准确性,也使推荐逻辑更透明化。

在个性化学习推荐系统中,为了增强学习者对推荐内容和路径合理性的理解,模型的可解释性至关重要。通过结合KG不仅能够提高模型的探测能力和分析能力,还能提供准

确的事实信息并清晰解释推荐背后的逻辑,为学习者提供更准确的学习内容,减少错误信息,从而增强学习者对模型的信任。此外,这种方法还能够帮助教师和研究人員识别和改进模型的潜在偏见和局限性,进一步提升个性化学习推荐系统的质量和效果,从而促进教育的个性化和精准化发展。

表1总结了KG对于LLM在预训练、推理结果、可解释性方面增强的方法,展示了LLM如何通过融合KG来优化个性化学习推荐系统,使它能够更精准地满足学习者的个性化需求,提供更有针对性的学习资源和路径,从而推动教育推荐系统向更高水平的个性化和智能化发展。

表1 知识图谱增强的大语言模型的特点

Tab. 1 Characteristics of knowledge graph enhanced large models

任务	方法	特点
知识图谱增强大语言模型预训练	ERNIE ^[41]	将多知识库信息融合到LLM的预训练阶段,能精确提供学习材料和解答问题,更准确地把握学习者的需求
	KnowBERT ^[42]	整合多知识库信息到LLM的预训练中,通过增强语义理解能力,实现精准的学习材料和问题答案推荐
	K-Adapter ^[43]	解决大型预训练模型在知识注入过程中的历史知识流失问题,实现学习者在持续学习过程中对新旧知识的累积与融合
	BioKGLM ^[44]	整合大规模知识图谱到外部结构中,根据学习者的当前知识水平推荐相关的病例分析、最新研究成果和相关治疗方法
知识图谱增强大语言模型推理结果	Chain-of-thought ^[45]	引入思维链提示词,增强模型复杂推理的能力,更准确地根据学习者的知识水平和需求推荐合适的学习资源和解决问题的步骤
	KGQA ^[50]	结合知识图谱的三元组与LLM的常识性知识,实现可验证事实的推理过程,提高个性化学习推荐的准确性和减少推理错误
	LLM $\otimes$ KG ^[49]	利用ToG在KG上迭代束搜索,探索相关实体和关系,执行深度推理,发现并返回最可能的推理结果,帮助学习者规划最佳学习路线
知识图谱增强大语言模型可解释性	RAG ^[54]	结合参数化内存和非参数化内存,以扩展模型的知识,并解决LLM中的幻觉问题
	HyKGE ^[57]	引入片段重新排序机制,动态调整推荐内容,提高推荐逻辑的透明度
	Explanation Dataset ^[56]	结合KG和GAT,增强结合在问题解答任务中的可解释性,提高个性化学习推荐的准确性,并使推荐逻辑更透明化
	GLAME ^[52]	结合KG和图知识编辑模块,强化结合的编辑过程,减少模型幻觉问题,提供更精准和可靠的知识推荐

4.2 大语言模型增强知识图谱

KG本身是多学科技术的综合体,也经常被笑称为“也只有知识图谱能够描绘清楚知识图谱的技术体系”。KG生来就与大数据技术、NLP技术、图计算、图学习、人工智能(Artificial Intelligence, AI)技术体系等相互融合互通,也正因为此,KG也更容易吸收融合其他的技术优势,LLM亦是如此。首先,LLM可以通过对实体和关系的文本描述进行编码来丰富KG的表示,帮助KG更好地捕捉实体和关系之间复杂的语义关系,提高知识图谱的表达力;其次,LLM能够对文本进行编码或生成事实,帮助KG识别文本中隐含关系,从而发现KG中缺失的连接以获得更好的KG补全性能,提高KG的完整性和准确性;最后,LLM可以生成实体描述、识别实体间的关系,并通过文本数据提取新的知识,促进KG构建,为KG中的实体和关系生成更丰富和详细的描述。

4.2.1 大语言模型优化知识图谱嵌入

知识图谱嵌入(Knowledge Graph Embedding, KGE)^[58]是一种被广泛采用的知识表示,主要思想是将知识图谱中的实体和关系嵌入连续的向量空间中,用来简化操作,同时保留KG的固有结构。KGE可以使多种下游任务受益,例如推荐任务、KG补全和KG构建。

传统的知识嵌入模型无法充分利用丰富的文本信息,相比之下,KE方法可以通过信息实体嵌入有效地在KG中表示关系事实。Wang等^[59]提出知识嵌入和预训练语言呈现统一的模型KEPLER(Knowledge Embedding and Pre-trained

Language Representation),它不仅能更好地将事实知识整合到PLM中,还能利用强大的PLM生成有效的文本增强知识库,从而生成与学习者目标紧密相关的知识内容,提供定制化的内容推荐。

传统的知识图谱嵌入方法主要依赖于知识图谱的结构信息,通过优化嵌入的评分函数(例如TransE^[60])实现。然而,这些方法在表示未见实体和长尾关系方面通常存在不足。针对这些问题,Su等^[61]提出一种名为Coke的新框架,能够根据学习者的特定上下文动态选择知识,确保提供的学习材料和信息与学习者当前的学习目标和需求高度相关,从而避免了KG中多余和模糊知识与输入文本不匹配的影响。Wang等^[62]提出的LMKE(Language Models as Knowledge Embeddings)采用LLM推导知识嵌入,旨在丰富长尾实体的表征。该方法不仅能够提升长尾实体的知识覆盖,增加学习材料的深度和多样性,支持定制化学习推荐路径,提高学习效率 and 效果,还能促进跨学科学习,增强学习体验的丰富性。

KGE技术的发展对于个性化学习推荐和知识管理具有重要意义。通过结合KG的结构化知识与文本信息,可以为学习者推荐更丰富和精准的学习资源。此外,动态选择和表示知识的方法能够更好地适应学习者的需求,避免不相关或模糊知识的干扰,从而提高学习体验的质量。总之,LLM作为一种人工智能技术,具有强大的语义理解和生成能力,可以不断学习和适应新的知识和技术,在多个方面增强KGE潜力,提高KG回答能力和个性化程度。

4.2.2 大语言模型增强知识图谱补全

知识图谱补全(Knowledge Graph Completion, KGC)是目前流行的知识补充技术之一,旨在学习知识图谱中现有的实体关系三元组,进而推断出知识图谱缺失的实体或关系补全增强知识图谱完整性^[63]。知识图谱的质量和完整性在很大程度上决定了下游任务的有效性。但是,鉴于知识库的不完整性,知识库中仍有大量有价值的知识被遗漏。因此,有必要改进现有的知识图谱,补充遗漏的知识^[18]。LLM作为一种强大的工具,一些基于LLM的方法被提出用于增强KGC。

由于KGC的性能仍然受到文本质量和结构不完整的限制,缺乏足够的实体描述,只能依赖关系名称,从而导致次优结果。Xu等^[64]提出MPIKGC(Multi-Perspective Improvement of KGC)这一通用框架,以弥补上下文知识的不足,为学习者提供更全面的学习材料并从不同角度查询LLM来改进KGC,其中包括利用LLM的推理、解释和总结能力分别扩展实体描述、理解关系和提取结构,为个性化学习推荐提供了更全面、深入的知识支持,从而提高学习效果和体验的完整性。通过预测潜在的三元组的可信度,将知识图谱的实体和关系转化为嵌入空间时,KGC方法通常会忽略知识图谱中包含以文字形式存储的更多文本信息。因此,学习过程仅限于实体之间的结构和联系,这有可能对学习效果产生负面影响。对此,Alam等^[65]引入了一个新的损失函数,使用Sentence-BERT和fastText作为预训练语言模型,从中获取文本知识的嵌入并注入损失函数。损失函数包含一个可训练的松弛变量,它决定语言模型对三元组可信度的影响程度,帮助学习者建立对学习材料的信任,从而更积极地参与学习。然而,这些方法大多只关注事实三元组文本的建模,而忽略了对KG建模具有重要意义的深层语义信息(如拓扑上下文和逻辑规则)。针对这一问题,Lin等^[66]提出一个统一的框架FTL-LM(Fuse Topology contexts and Logical rules in Language Models),在KGC语言模型中融合拓扑上下文和逻辑规则。该框架主要包含一种基于路径的拓扑上下文学习新方法和一种用于软逻辑规则提炼的变分期望最大化(Expectation-Maximization, EM)算法。前者利用异构随机漫步生成拓扑路径和进一步的推理路径,它们能隐式地表示拓扑上下文,也能显式地由大语言模型(Language Model, LM)建模。为了建模这些拓扑上下文,引入掩码语言建模和对比路径学习策略。后者通过EM算法隐式地融合逻辑规则与2个LM。这种方法不仅提高了知识补全的准确性,还能根据用户的反馈和学习进展,实时调整推荐的知识内容,确保推荐内容的持续相关性和准确性,增强学习者的可信度。

KGC技术的改进对于构建高质量和高完整性的KG至关重要。通过结合LLM和先进的建模技术可以更好地理解和补全知识图谱中的缺失部分,从而为推荐任务提供更准确的支持。此外,这种方法不仅提高了KG的质量,还能够增加学习体验的丰富性和深度,促进知识的深度整合和应用。

4.2.3 大语言模型增强知识图谱构建

知识图谱构建是指对特定领域内创建的知识进行结构化表示^[67]。徐增林等^[68]将知识图谱的构建分为知识抽取、知识表示、知识融合、知识推理4个方面。

LLM的语言理解和生成能力与知识图谱结合为知识抽取、知识表示、知识融合和知识推理提供了新的视角和方法。

1) LLM增强知识抽取:知识抽取的目的是从自然语言文

本中提取结构性知识(如实体、关系、事件等),由于特定的任务模式和复杂的文本表达,这给现有方法带来了挑战。代码作为一种典型的形式化语言,能够通用地描述各种模式下的结构知识。另一方面,基于代码和文本训练的LLM已经被证实有将文本转化为代码的强大能力,为信息环境任务提供了可行的解决方案。因此,Guo等^[69]提出一种基于LLM的通用检索增强代码生成框架Code4UIE(Code for Universal Information Extraction),采用Python类以通用方式定义各种结构知识的特定任务模式,应用于知识抽取任务中。这种方法不仅提高了知识抽取的准确性和效率,还支持复杂文本表达的处理,通过分析用户的学习路径和需求,推荐最相关和有价值的知识内容,提升学习效果。

2) LLM增强知识表示:知识表示是指如何用大语言模型增强知识图谱实体、概念和它们之间的关系以一种适合计算机处理的形式进行编码。LLM可以将文本实体描述编码成嵌入向量以增强知识表示。Ke等^[70]提出一种知识图谱-文本联合表征学习模型JointGT(Graph-Text Joint representation learning),通过预训练任务对齐知识图谱和文本的表征,增强知识表示的能力,有助于学习者建立对复杂概念和关系的深入理解,对于掌握高级知识和技能至关重要。

3) LLM增强知识融合:知识融合是指将来自不同来源的知识整合到一个统一的知识库中。LLM可以通过提供文本和语言理解能力辅助知识融合过程。对此,Yasunaga等^[71]提出一种自监督方法DRAGON(Deep bidirectional Language-knowledge graph pretraining),即深度双向语言知识图谱预训练,用于大规模预训练来自文本和知识图谱的深度联合语言知识基础模型。DRAGON将成对的文本片段和相关的语言知识子图作为输入,并双向融合2种模式的信息,可以显著提升知识表示的丰富性和问题解答的能力,支持多模态学习,提高学习效率,并增强学习的个性化体验。

4) LLM增强知识推理:知识推理是指利用知识图谱中的信息进行逻辑推导,得出新的结论或验证假设。LLM可以通过生成逻辑查询或与知识图谱结合执行推理任务。然而,现有的知识推理方法仅将知识图谱视为事实知识库,忽略了结构信息对推理的重要性。Luo等^[72]提出一种名为图推理(Reasoning on Graphs, RoG)的新方法,从KG中提炼知识,通过训练提高LLM的推理能力,还能在推理过程中与任意LLM无缝集成,从KG中检索有效的推理路径,从而实现可靠且可解释的推理。RoG能够实时检索和更新KG中的信息,动态调整推荐内容。这种动态调整机制能确保推荐内容与学习者的需求保持一致,增强推荐内容多样性和新颖性。

综上所述,LLM在知识图谱构建中的应用为该领域带来了新的可能性。利用LLM的语言理解和生成能力,可以更有效地处理和整合知识,提供更丰富和准确的知识表示,以及执行更复杂和可解释的推理任务。这些进展不仅推动了知识图谱技术的发展,也为个性化学习推荐和教育领域带来了实质性的好处,使学习体验更丰富、互动和高效。随着技术的不断进步,未来的知识图谱构建和应用将更智能化和个性化,更好地服务于人类的知识需求和学习发展。

表2总结了LLM对于KG嵌入、补全、构建方面增强的方法,利用LLM的文本处理能力提升KG的语义理解、完整性和更新效率,进而为个性化学习推荐系统提供更准确、可解释的推荐依据。

表2 大语言模型增强的知识图谱的特点

Tab. 2 Characteristics of large model enhanced knowledge graphs

任务	方法	特点
大语言模型增强知识图谱嵌入	KEPLER ^[59]	将事实知识整合到PLM中且利用强大的PLM生成有效文本增强知识库,生成与学习者目标紧密相关的知识内容,提供定制化的内容推荐
	Coke ^[61]	根据PLM的文本上下文动态选择上下文知识并嵌入知识上下文,动态推荐与学习者当前学习目标和需求紧密相关的知识
	LMKE ^[62]	采用大语言模型来推导知识嵌入,丰富长尾实体的表征,增加学习材料的深度和多样性,提升学习效率和跨学科学习体验
大语言模型增强知识图谱补全	MPIKGC ^[64]	增强对实体描述的理解,深化对关系的理解,通过预测潜在三元组的可信度,利用知识图谱中的文本信息,提高推荐内容的完整性和准确性
	loss function ^[65]	能够调节大语言模型对知识三元组可信度的评估,从而帮助学习者建立对学习材料的信任,并更积极地参与学习过程
	FTL-LM ^[66]	结合基于路径的拓扑上下文学习和变分EM算法提炼的软逻辑规则,使推荐内容能够实时适应学习者的反馈和进展
大语言模型增强知识图谱构建	Code4UIE ^[69]	结合大语言模型的通用检索增强能力,定义Python类处理结构化知识,分析用户的学习路径和需求,推荐最相关和有价值的知识内容
	JointGT ^[70]	通过预训练任务来对齐知识图谱和文本的表征,促进学习者对复杂概念和关系的深入理解
	DRAGON ^[71]	将成对的文本片段和相关的语言知识子图作为输入,并双向融合两种模式的信息,支持多模态学习
	RoG ^[72]	提炼知识图谱中的信息实现与任意LLM的无缝集成,检索有效的推理路径,实时更新知识图谱信息和动态调整推荐内容

5 问题与挑战

当前,个性化学习推荐作为教育创新的关键方向,正逐渐成为推动教育变革的重要力量,得到了广泛关注和应用。研究者们通过结合KG和LLM提出许多先进的学习推荐方法,促进学习推荐更精准和高效。但是,个性化学习推荐领域中仍然存在数据稀缺、推荐解释性差、多模态特征提取的局限性等问题。针对上述问题,提出了几个学习推荐未来值得研究的方向。

1) 优化学习推荐算法。

目前推荐算法可以通过分析学习资源的内容特征以及学习者偏好来推荐相似的资源。但是,由于缺乏足够的交互数据,推荐系统无法快速适应学习者的学习兴趣和需求随时间的变化,推荐缺乏实时性。针对这一问题,首先,知识图谱提供结构化的信息存储和关系管理,便于快速查询和推荐;其次,将LLM用于处理和理解用户的自然语言查询,解析复杂的问题和需求;最后,通过结合知识图谱中的结构化信息与LLM的语义理解能力推荐系统可以进行上下文感知推荐,即使在交互数据有限的情况下也能提供相关资源。

2) 优化LLM和KG理论和方法。

首先,LLM在大规模数据中训练和预测会受到错误标注、不准确的信息或噪声数据的影响,并且LLM是黑盒模型,它的决策过程通常是不透明的,用户难以理解模型是如何得出特定输出的;其次,KG中实体和关系的表示需要捕捉它们之间的复杂语义关系,这在不同领域和不同数据源中尤为困难;最后,LLM和KG的训练和推理过程需要大量的计算资源,尤其是GPU和内存,这可能导致成本增加和效率降低。针对上述问题,可以采取多种策略,包括通过数据清洗和增强技术提高数据质量,开发高效的训练算法以降低计算资源需求,采用本体学习和规则推理等先进技术进行知识融合,以及引入可解释性机制增强模型透明度和用户信任,使它在各种推荐应用中更准确、高效和用户友好。

3) 优化知识图谱补全性能。

自动化或人工采集数据的过程中可能存在选择偏差,导

致某些类型的实体或关系被过度表示,而其他类型则被忽略或遗漏。此外,数据集中可能包含错误、模糊或过时的信息。这些问题可能导致知识图谱补全的准确性和效率不高,影响个性化学习推荐效果。为了解决以上问题,首先,可以通过平衡采样和多样性增强策略确保数据的均衡代表性;其次,实施严格的数据清洗和验证流程来提高数据质量;最后,不断优化数据采集策略,结合多源数据融合和策略调整,以减小单一数据源的偏差。

4) 优化知识图谱构建性能。

KG涉及庞大的数据量,这要求算法能够高效地处理和分析大规模数据集,但是,数据来自不同的渠道,如公开数据库、网络爬虫、社交媒体等。每种数据源都有特定的格式和结构,增加了整合和预处理的复杂性;而且数据中的实体和关系在现实世界中具有丰富的语义,需要准确捕捉这些语义信息以便于机器理解和处理。针对以上问题,可以开发更先进的数据抽取和融合技术,利用机器学习和自然语言处理技术提高自动化构建的准确性,同时,探索高效的知识表示和存储方法,进而构建更丰富和动态更新的知识图谱,为个性化学习推荐提供坚实的知识基础。

5) 大语言模型和知识图谱在跨语言、跨领域、跨媒体等多模态场景下的应用。

首先,不同语言的语法、词汇、表达方式和语境差异很大程度上会导致LLM在信息理解和处理的复杂性增加;其次,特定领域的专业知识通常包含复杂的术语和概念,模型需要具备深入的领域知识才能提供有效的推荐;最后,不同类型的媒体数据,如文本、图像、音频、视频等,需要不同的处理方法和技术,增加了数据融合的难度。针对这些问题,可以开发更强大的多模态理解和表示技术,利用迁移学习和多任务学习提高模型的泛化能力,并构建更综合的知识图谱以整合不同领域的知识。此外,引入学习者反馈和持续学习机制,可以不断优化模型以适应学习者的个性化需求。通过上述方法有助于综合考虑多模态信息,以提供更全面的理解,实现更精准和灵活的个性化学习推荐系统,为学习者提供更丰富、相关和互动的学习内容,无论学习者的语言背景、知识水

平或学习偏好如何。

6) 优化大语言模型与知识图谱的评估方法与技术。

大语言模型和知识图谱推荐系统需要制定多样化的评估标准准确衡量系统性能。在评估过程中,面临缺乏足够交互数据来评估系统性能以及评估方法应具有跨领域的适用性等挑战。针对上述问题,首先,可以开发包含准确性、多样性、新颖性、健壮性、可解释性等多个维度的评估标准,以全面衡量推荐系统的性能;其次,利用迁移学习技术,将在其他领域或任务上训练的模型应用到目标领域,以缓解数据不足的问题;最后,建立开放的评估平台,允许研究人员和开发者共享评估工具、数据集和基准,促进公平比较和快速迭代。

6 结语

个性化学习推荐是一种利用算法和模型为学习者提供定制化学习资源和学习路径的教育技术应用。近几年个性化学习推荐作为热门的研究方向,得到了越来越多学者的关注。随着 KG 和 LLM 技术的快速发展,基于 KG 和 LLM 的个性化学习推荐逐渐成为研究热点。因此,通过阅读近年来大部分有关个性化学习推荐的方法和应用的文献,本文对个性化学习推荐进行了较为系统的综述。首先,介绍个性化学习推荐同时,重点分析讨论了现如今流行的基于 KG 和 LLM 的个性化学习推荐方法;其次,总结了在个性化学习推荐中 KG 优化 LLM 预训练、推理结果、可解释性以及 LLM 优化 KG 嵌入、补全、构建的方法;最后,对这两类方法的未来研究趋势进行了展望和总结,为该领域的研究提供有价值的见解和启示。未来研究需要在技术、理论和实践层面进行深入探索,以解决现有挑战并推动个性化学习推荐领域的持续发展和创新。

参考文献 (References)

- [1] 赵宇博,张丽萍,闫盛,等. 个性化学习中学科知识图谱构建与应用综述[J]. 计算机工程与应用, 2023, 59(10): 1-21. (ZHAO Y B, ZHANG L P, YAN S, et al. Construction and application of discipline knowledge graph in personalized learning [J]. Computer Engineering and Applications, 2023, 59(10): 1-21.)
- [2] 李兴洲,徐莉,姬冰澌. 教育未来发展新趋势:迈向新人文主义的终身教育——基于联合国教科文组织前瞻性教育报告[J]. 清华大学教育研究, 2023, 44(3): 65-74. (LI X Z, XU L, JI B S. The new trend of the future development of education: towards the lifelong education of new humanism — an analysis based on the UNESCO's education reports [J]. Tsinghua Journal of Education, 2023, 44(3): 65-74.)
- [3] IDRISSE N, ZELLOU A, HOURRANE O, et al. Addressing cold start challenges in recommender systems: towards a new hybrid approach [C]// Proceedings of the 2019 International Conference on Smart Applications, Communications and Networking. Piscataway: IEEE, 2019: 1-6.
- [4] 牟智佳. “人工智能+”时代的个性化学习理论重思与开解[J]. 远程教育杂志, 2017, 35(3): 22-30. (MOU Z J. The reconsideration and solution of personalized learning theory in the era of “artificial intelligence plus” [J]. Journal of Distance Education, 2017, 35(3): 22-30.)
- [5] JI Z, LEE N, FRIESKE R, et al. Survey of hallucination in natural language generation [J]. ACM Computing Surveys, 2023, 55(12): No. 248.
- [6] PAN S, LUO L, WANG Y, et al. Unifying large language models and knowledge graphs: a roadmap [J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(7): 3580-3599.
- [7] 吴正洋,汤庸,刘海. 个性化学习推荐研究综述[J]. 计算机科学与探索, 2022, 16(1): 21-40. (WU Z Y, TANG Y, LIU H. Survey of personalized learning recommendation [J]. Journal of Frontiers of Computer Science and Technology, 2022, 16(1): 21-40.)
- [8] 吴国栋,刘旭旭,毕海娇,等. 基于元学习个性化推荐研究综述[J]. 计算机工程与科学, 2024, 46(2): 338-352. (WU G D, LIU X X, BI H J, et al. Review of personalized recommendation research based on meta-learning [J]. Computer Engineering and Science, 2024, 46(2): 338-352.)
- [9] 赵俊逸,庄福振,敖翔,等. 协同过滤推荐系统综述[J]. 信息安全学报, 2021, 6(5): 17-34. (ZHAO J Y, ZHUAN F Z, AO X, et al. Survey of collaborative filtering recommender systems [J]. Journal of Cyber Security, 2021, 6(5): 17-34.)
- [10] 于蒙,何文涛,周绪川,等. 推荐系统综述[J]. 计算机应用, 2022, 42(6): 1898-1913. (YU M, HE W T, ZHOU X C, et al. Review of recommender system [J]. Journal of Computer Applications, 2022, 42(6): 1898-1913.)
- [11] 高琳琦. 生成式人工智能在个性化学习中的应用模式[J]. 天津师范大学学报(基础教育版), 2023, 24(4): 36-40. (GAO L Q. Application method of generative artificial intelligence in personalized learning [J]. Journal of Tianjin Normal University (Elementary Education Edition), 2023, 24(4): 36-40.)
- [12] Wikipedia. Google Knowledge graph [EB/OL]. [2024-01-09]. https://en.wikipedia.org/wiki/Knowledge_Graph.
- [13] 李源,马新宇,杨国利,等. 面向知识图谱和大语言模型的因果关系推断综述[J]. 计算机科学与探索, 2023, 17(10): 2358-2376. (LI Y, MA X Y, YANG G L, et al. Survey of causal inference for knowledge graphs and large language models [J]. Journal of Frontiers of Computer Science and Technology, 2023, 17(10): 2358-2376.)
- [14] 延照耀,丁苍峰,马乐荣,等. 面向图神经网络的知识图谱嵌入研究进展[J]. 计算机科学与探索, 2023, 17(8): 1793-1813. (YAN Z Y, DING C F, MA L R, et al. Advances in knowledge graph embedding based on graph neural networks [J]. Journal of Frontiers of Computer Science and Technology, 2023, 17(8): 1793-1813.)
- [15] ILIEVSKI F, SZEKELY P, ZHANG B. CSKG: the commonsense knowledge graph [C]// Proceedings of the 2021 European Semantic Web Conference, LNCS 12731. Cham: Springer, 2021: 680-696.
- [16] ABU-SALIH B. Domain-specific knowledge graphs: a survey [J]. Journal of Network and Computer Applications, 2021, 185: No. 103076.
- [17] 王春雷,王肖,刘凯. 多模态知识图谱表示学习综述[J]. 计算机应用, 2024, 44(1): 1-15. (WANG C L, WANG X, LIU K. Multimodal knowledge graph representation learning: a review [J]. Journal of Computer Applications, 2024, 44(1): 1-15.)
- [18] SHEN T, ZHANG F, CHENG J. A comprehensive overview of knowledge graph completion [J]. Knowledge-Based Systems, 2022, 255: No. 109597.
- [19] 王宇,朱梦霞,杨尚辉,等. 深度知识追踪模型综述和性能比较[J]. 软件学报, 2023, 34(3): 1365-1395. (WANG Y, ZHU M X, YANG S H, et al. Review and performance comparison of deep knowledge tracking models [J]. Journal of Software, 2023, 34(3): 1365-1395.)
- [20] ZHANG J, JING S, LIANG S. Research on personalized learning resource recommendation based on knowledge graph [C]// Proceedings of the 3rd International Conference on Electronic Information Engineering and Computer Communication. Piscataway: IEEE, 2023: 111-118.

- [21] LI B, LI G, XU J, et al. A personalized recommendation framework based on MOOC system integrating deep learning and big data [J]. Computers and Electrical Engineering, 2023, 106: No. 108571.
- [22] ZHANG S, HUI N, ZHAI P, et al. A fine-grained and multi-context-aware learning path recommendation model over knowledge graphs for online learning communities [J]. Information Processing and Management, 2023, 60(5): No. 103464.
- [23] ZHANG X, LIU S, WANG H. Personalized learning path recommendation for e-learning based on knowledge graph and graph convolutional network [J]. International Journal of Software Engineering and Knowledge Engineering, 2023, 33(1): 109-131.
- [24] SHOU Z, WEN Y, CHEN P, et al. Personalized knowledge map recommendations based on interactive behavior preferences [J]. International Journal of Performability Engineering, 2021, 17(1): 36-49.
- [25] DUAN S, CHEN K, YANG Y, et al. Research on personalized learning recommendation based on subject knowledge graphs and learner portraits [C]// Proceedings of the 2023 International Conference on Computer Science and Educational Informatization, CCIS 1900. Singapore: Springer, 2024: 367-374.
- [26] JUNG H, JANG Y, KIM S, et al. KPCR: knowledge graph enhanced personalized course recommendation [C]// Proceedings of the 2021 Australasian Joint Conference on Artificial Intelligence, LNCS 13151. Cham: Springer, 2022: 739-750.
- [27] WEI Z, WANG K, LI F, et al. M³KGR: a momentum contrastive multi-modal knowledge graph learning framework for recommendation [J]. Information Sciences, 2024, 676: No. 120812.
- [28] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision [C]// Proceedings of the 38th International Conference on Machine Learning. New York: JMLR.org, 2021: 8748-8763.
- [29] SUN R, CAO X, ZHAO Y, et al. Multi-modal knowledge graphs for recommender systems [C]// Proceedings of the 29th ACM International Conference on Information and Knowledge Management. New York: ACM, 2020: 1405-1414.
- [30] 徐月梅, 胡玲, 赵佳艺, 等. 大语言模型与多语言智能的研究进展与启示[J]. 计算机应用, 2023, 43(S2): 1-8. (XU Y M, HU L, ZHAO J Y, et al. Research progress and enlightenment of large language models on multi-lingual intelligence [J]. Journal of Computer Applications, 2023, 43(S2): 1-8.)
- [31] 董永峰, 王雅琮, 董瑶, 等. 在线学习资源推荐综述[J]. 计算机应用, 2023, 43(6): 1655-1663. (DONG Y F, WANG Y C, DONG Y, et al. Survey of online learning resource recommendation [J]. Journal of Computer Applications, 2023, 43(6): 1655-1663.)
- [32] 王佑镁, 王旦, 梁炜怡, 等. “阿拉丁神灯”还是“潘多拉魔盒”: ChatGPT 教育应用的潜能与风险[J]. 现代远程教育研究, 2023, 35(2): 48-56. (WANG Y M, WANG D, LIANG W Y, et al. “Aladdin’s Lamp” or “Pandora’s Box”: the potential and risks of ChatGPT’s educational applications [J]. Modern Distance Education Research, 2023, 35(2): 48-56.)
- [33] ROMBACH R, BLATTMANN A, LORENZ D, et al. High resolution image synthesis with latent diffusion models [C]// Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 10684-10695.
- [34] 徐国庆, 蔡金芳, 姜蓓佳, 等. ChatGPT/生成式人工智能与未来职业教育[J]. 华东师范大学学报(教育科学版), 2023, 41(7): 64-77. (XU G Q, CAI J F, JIANG B J, et al. ChatGPT/AIGC and the future vocational education [J]. Journal of East China Normal University (Educational Sciences), 2023, 41(7): 64-77.)
- [35] JI J, LI Z, XU S, et al. GenRec: large language model for generative recommendation [C]// Proceedings of the 2024 European Conference on Information Retrieval, LNCS 14610. Cham: Springer, 2024: 494-502.
- [36] SRIVASTAV G, KANT S, SRIVASTAVA D. An efficient sentiment analysis technique for virtual learning environments using deep learning model and fine-tuned EdBERT [J]. International Journal of Intelligent Systems and Applications in Engineering, 2023, 11(5s): 468-476.
- [37] KIM D E, HONG C, KIM W H. Efficient Transformer-based knowledge tracing for a personalized language education application [C]// Proceedings of the 10th ACM Conference on Learning @ Scale. New York: ACM, 2023: 336-340.
- [38] GENG S, LIU S, FU Z, et al. Recommendation as Language Processing (RLP): a unified Pretrain, Personalized Prompt & Predict Paradigm (P5) [C]// Proceedings of the 16th ACM Conference on Recommender Systems. New York: ACM, 2022: 299-315.
- [39] LIU J, LIU C, ZHOU P, et al. Is ChatGPT a good recommender? a preliminary study [EB/OL]. [2024-03-11]. <https://arxiv.org/pdf/2304.10149>.
- [40] XU A, MONROE W, BICKNELL K. Large language model augmented exercise retrieval for personalized language learning [C]// Proceedings of the 14th Learning Analytics and Knowledge Conference. New York: ACM, 2022: 284-294.
- [41] ZHANG Z, HAN X, LIU Z, et al. ERNIE: enhanced language representation with informative entities [C]// Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2019: 1441-1451.
- [42] PETERS M E, NEUMANN M, LOGAN R L, IV, et al. Knowledge enhanced contextual word representations [C]// Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. Stroudsburg: ACL, 2019: 43-54.
- [43] WANG R, TANG D, DUAN N, et al. K-Adapter: infusing knowledge into re-trained models with adapters [C]// Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021. Stroudsburg: ACL, 2021: 1405-1418.
- [44] FEI H, REN Y, ZHANG Y, et al. Enriching contextualized language model from knowledge graph for biomedical information extraction [J]. Briefings in Bioinformatics, 2021, 22(3): No. bbaa110.
- [45] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models [C]// Proceedings of the 36th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2022: 24824-24837.
- [46] AHN J, VERMA R, LOU R, et al. Large language models for mathematical reasoning: progresses and challenges [C]// Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: Student Research Workshop. Stroudsburg: ACL, 2024: 225-237.
- [47] CHU Z, CHEN J, CHEN Q, et al. A survey of chain of thought reasoning: advances, frontiers and future [EB/OL]. [2024-02-10]. <https://arxiv.org/pdf/2309.15402>.
- [48] HU C, FU J, DU C, et al. ChatDB: augmenting LLMs with databases as their symbolic memory [EB/OL]. [2024-01-25]. <https://arxiv.org/pdf/2306.03901>.

- [49] SUN J, XU C, TANG L, et al. Think-on-Graph: deep and responsible reasoning of large language model with knowledge graph [EB/OL]. [2024-01-25]. <https://arxiv.org/pdf/2307.07697>.
- [50] TOROGHI A, GUO W, ABDOLLAH POUR M M, et al. Right for right reasons: large language models for verifiable commonsense knowledge graph question answering [C]// Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2024: 6601-6633.
- [51] ZHAO H, CHEN H, YANG F, et al. Explainability for large language models: a survey [J]. ACM Transactions on Intelligent Systems and Technology, 2024, 15(2): No. 20.
- [52] ZHANG M, YE X, LIU Q, et al. Knowledge graph enhanced large language model editing [EB/OL]. [2024-04-02]. <https://arxiv.org/pdf/2402.13593>.
- [53] AGRAWAL G, KUMARAGE T, ALGHAMI Z, et al. Can knowledge graphs reduce hallucinations in LLMs? a survey [C]// Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). Stroudsburg: ACL, 2024: 3947-3960.
- [54] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks [C]// Proceedings of the 34th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2020: 9459-9474.
- [55] RAM O, LEVINE Y, DALMEDIGOS I, et al. In-context retrieval-augmented language models [J]. Transactions of the Association for Computational Linguistics, 2023, 11: 1316-1331.
- [56] CHEN Z, CHEN J, SINGH A, et al. XplainLLM: a knowledge-augmented dataset for reliable grounded explanations in LLMs [C]// Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2024: 7578-7596.
- [57] JIANG X, ZHANG R, XU Y, et al. HyKGE: a hypothesis knowledge graph enhanced framework for accurate and reliable medical LLMs responses [EB/OL]. [2024-02-11]. <https://arxiv.org/pdf/2312.15883v2>.
- [58] 张天成, 田雪, 孙相会, 等. 知识图谱嵌入技术研究综述[J]. 软件学报, 2023, 34(1): 277-311. (ZHANG T C, TIAN X, SUN X H, et al. Overview on knowledge graph embedding technology research [J]. Journal of Software, 2023, 34(1): 277-311.)
- [59] WANG X, GAO T, ZHU Z, et al. KEPLER: a unified model for knowledge embedding and pre-trained language representation [J]. Transactions of the Association for Computational Linguistics, 2021, 9: 176-194.
- [60] BORDES A, USUNIER N, GARCIA-DURÁN A, et al. Translating embeddings for modeling multi-relational data [C]// Proceedings of the 27th International Conference on Neural Information Processing Systems — Volume 2. Red Hook: Curran Associates Inc., 2013: 2787-2795.
- [61] SU Y, HAN X, ZHANG Z, et al. CokeBERT: contextual knowledge selection and embedding towards enhanced pre-trained language models [J]. AI Open, 2021, 2: 127-134.
- [62] WANG X, HE Q, LIANG J, et al. Language models as knowledge embeddings [C]// Proceedings of the 31st International Joint Conference on Artificial Intelligence. California: IJCAI.org, 2022: 2291-2297.
- [63] 彭晏飞, 张睿思, 王瑞华, 等. 少样本知识图谱补全技术研究[J]. 计算机科学与探索, 2023, 17(6): 1268-1284. (PENG Y F, ZHANG R S, WANG R H, et al. Survey on few-shot knowledge graph completion technology [J]. Journal of Frontiers of Computer Science and Technology, 2023, 17(6): 1268-1284.)
- [64] XU D, ZHANG Z, LIN Z, et al. Multi-perspective improvement of knowledge graph completion with large language models [C]// Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation. Stroudsburg: ACL, 2024: 11956-11968.
- [65] ALAM M M, RONY M R A H, NAYYERI M, et al. Language model guided knowledge graph embeddings [J]. IEEE Access, 2022, 10: 76008-76020.
- [66] LIN Q, MAO R, LIU J, et al. Fusing topology contexts and logical rules in language models for knowledge graph completion [J]. Information Fusion, 2023, 90: 253-264.
- [67] 阮彤, 王梦婕, 王昊奋, 等. 垂直知识图谱的构建与应用研究[J]. 知识管理论坛, 2016, 1(3): 226-234. (RUAN T, WANG M J, WANG H F, et al. Research on the construction and application of vertical knowledge graphs [J]. Knowledge Management Forum, 2016, 1(3): 226-234.)
- [68] 徐增林, 盛泳潘, 贺丽荣, 等. 知识图谱技术综述[J]. 电子科技大学学报, 2016, 45(4): 589-606. (XU Z L, SHENG Y P, HE L R, et al. Review on knowledge graph techniques [J]. Journal of University of Electronic Science and Technology of China, 2016, 45(4): 589-606.)
- [69] GUO Y, LI Z, JIN X, et al. Retrieval-augmented code generation for universal information extraction [C]// Proceedings of the 2024 CCF International Conference on Natural Language Processing and Chinese Computing. Singapore: Springer, 2025: 30-42.
- [70] KE P, JI H, RAN Y, et al. JointGT: graph-text joint representation learning for text generation from knowledge graphs [C]// Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021. Stroudsburg: ACL, 2021: 2526-2538.
- [71] YASUNAGA M, BOSSELUT A, REN H, et al. Deep bidirectional language-knowledge graph pretraining [C]// Proceedings of the 36th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2022: 37309-37323.
- [72] LUO L, LI Y F, HAFFARI G, et al. Reasoning on graphs: faithful and interpretable large language model reasoning [EB/OL]. [2024-03-01]. <https://arxiv.org/pdf/2310.01061>.

This work is partially supported by National Natural Science Foundation of China (61462071); Inner Mongolia Natural Science Foundation (2023LHMS06009, 2024MS06020); Inner Mongolia Autonomous Region Education Science Research “14th Five-Year Plan” 2023 Project (2023NGHZXZH119, NGJGH2023234).

ZHANG Xuefei, born in 1997, M. S. candidate. His research interests include computer education.

ZHANG Liping, born in 1974, M. S., professor. Her research interests include smart education, software engineering.

YAN Sheng, born in 1984, M. S., lecturer. His research interests include computer education.

HOU Min, born in 1973, M. S., associate professor. Her research interests include computer education.

ZHAO Yubo, born in 1999, M. S. candidate. His research interests include knowledge graph, educational data mining.